

Kaggle-CIBMTR - Equity in post-HCT Survival Predictions

项目背景：提升接受异体造血细胞移植（HCT）患者的移植存活率预测

评价指标：分层一致性指数（C-index）

一致性指数（C-index）是生存分析中评估模型预测效果的核心指标，取值范围在 0.5（随机猜测）到 1.0（完美预测）之间，值越高说明预测效果越好。

按 `race_group`（种族分组）分别计算每组的一致性指数（C-index），返回「所有种族分组 C-index 的均值 - 这些 C-index 的标准差」作为最终评分

数据介绍：

数据集包含59个与造血干细胞移植（HSCT）相关的变量，涵盖受体和捐献者的多种人口统计和医疗特征，如年龄、性别、族裔、疾病状况及治疗细节。主要关注的结果是无事件存活，由变量`efs`表示，而到无事件生存的时间则由变量`efs_time`表示。这两个变量共同编码了用于审查事件时间分析的目标。

项目重点：

1. 预测患者发生事件的概率（`efs`）
2. 预测发生事件的患者的排名（`efs_time`）

自己方案：


深度学习方案：

通过多目标回归拟合`cox`目标以及基于数据中的 `efs`（二元标识，取值为 0 或 1）和 `efs_time`（时间类数值）字段，通过数值偏移、排序、缩放、对数变换、中心化、符号反转等一系列操作，构建一个自定义的目标变量 `y`，拉大 0/1 类样本的差距，用CNN和DNN网络进行预测

机器学习方案：

分别用两套特征，对xgb进行了一个分类预测efs，然后用xgb对cox，kap，custom目标进行回归，lgb和cat对kap目标进行拟合回归。对于efs=1的患者重点关注，加一定数值

对上述模型赋予不同权重进行加权融合



前排方案：

训练 CatBoost 分类模型，预测“样本是否（efs==0）”：

- 1.分层交叉验证：按 **efs+race_group** 分层，避免某种族 / 事件类型在验证集占比失衡；
- 2.模型参数：适配二分类任务（Logloss 损失），优化 AUC 指标，设置子采样 / 列采样防止过拟合；
- 3.OOF 预测：保存各折验证集的预测结果，用于后续模型融合；

训练 LightGBM 回归模型，预测生存时间的归一化排名：

- 1.回归目标构建：按 **efs** 分组对 **efs_time** 做归一化排名（消除不同分组的量纲差异）；
- 2.样本权重：侧重事件发生样本（权重 0.6），因为这类样本的生存时间更有参考价值；

3.特征新增：将efs作为特征输入；

搜索回归和分类的非线性加权融合比例，得到最优分数